Généralisation aux quatre éditions du CGI

Bilan des sources, de l'extraction et des index candidats - 14 octobre 2026

Décision actuelle

Les éditions 2023 à 2026 sont extraites et indexées dans un espace candidat. La configuration de l'application et le ZIP de démonstration n'ont pas été remplacés. Les résultats ci-dessous établissent la faisabilité technique de cette étape, pas encore la qualité des réponses sur tout le CGI.

Combien de chunks ?

9 062 passages indexés : 2 208 (2023), 2 239 (2024), 2 296 (2025) et 2 319 (2026). Ils proviennent de 1 443 articles extraits. Une note est conservée séparément ; les 7 166 notes ne constituent donc pas 7 166 chunks supplémentaires. Le découpage reste celui convenu : 220 mots maximum et deux lignes de chevauchement. Les 511 anciens passages ont été retrouvés à texte, structure et pagination identiques.

1. Sources et extraction

Édition	Pages du PDF	Corps du CGI (pages PDF)	Articles	Notes
2023	694	5-492	349	1 641
2024	726	4-505	352	1 733
2025	750	4-522	370	1 860
2026	765	5-529	372	1 932

Les quatre empreintes locales correspondent au manifeste des sources. Couvertures, langue, début du code et transition vers les annexes ont été contrôlés sur les PDF présents. Le sommaire et l'article de la loi instituant le CGI ne sont pas comptés comme articles du code. Les numéros principaux 1 à 292 ou 303 sont présents sans rupture ni doublon ; 761 articles traversent plusieurs pages. Les références de page PDF et de page imprimée restent distinctes.

Limite visible : 175 alertes d'extraction, dont 84 notes au rattachement incertain, 46 intitulés d'articles abrogés sans corps et 37 petits textes non classés. Ces alertes ne sont pas converties silencieusement en données certaines.

Index candidat et capacité de l'architecture

Ce qui est démontré, puis ce qui reste à prouver

2. Index et contrôle technique

BM25, les vecteurs E5 et une collection Chroma distincte ont été construits sur les 9 062 passages. E5 a été calculé sur la RTX 4060 avec une roue PyTorch CUDA isolée ; les lots ont pris 52,7 s hors chargement et audit préalable, et la VRAM échantillonnée a culminé à 11,8 %. Chroma utilise son index HNSW sur CPU. Quatre passages de l'article 92 dépassent de 20 tokens la limite d'entrée E5 de 512 tokens : cette troncature du seul encodage est consignée, tandis que les textes complets restent stockés.

Sonde	Résultat	Interprétation correcte
24 requêtes	Top 5 dense et hybride identique à l'exhaustif pour 24/24, dès 64 candidats Chroma.	Contrôle de classement technique sur ces sondes, pas mesure de pertinence juridique globale.
Latence Chroma	Médiane d'environ 13,8 ms pour la requête à 64 candidats.	Exclut l'encodage de la question, BM25, la fusion, le contexte et Qwen.
Tests existants	74 tests passent.	Vérifie l'absence de régression couverte par ces tests ; pas une campagne de réponse sur quatre éditions.

L'architecture actuelle peut-elle traiter cette taille ?

Les composants, oui ; l'application active, pas encore telle quelle. Les artefacts candidats sont de taille locale modérée : index BM25 JSON 40,8 Mo, vecteurs E5 13,9 Mo et base SQLite Chroma 73,7 Mo. La recherche Chroma bornée a fonctionné sur les quatre éditions. Mais le retriever actif n'accepte explicitement que 2023 et 2025 ; son stockage Chroma est figé aux 511 passages initiaux et interroge tous les candidats. Le constructeur de contexte charge aussi le corpus actif. Ces liaisons doivent être adaptées avant une bascule.

Ce qui peut réellement devenir difficile

Point à surveiller	Pourquoi cela compte
Fidélité des preuves	Une note mal liée ou une subdivision mal découpée peut produire une réponse plausible mais fausse.
Contexte parent	L'article 247 atteint environ 10 800 mots en 2026 ; il ne doit pas entrer entier dans les 8 192 tokens configurés pour Qwen.
Recherche par édition	Le filtre doit précéder le classement et rester vrai jusqu'aux citations ; il faut tester les passages semblables entre années.
Latence et ressources	Mesurer le parcours complet à froid et à chaud, avec E5 et Qwen simultanés, pas seulement la requête Chroma.

Travail restant avant la bascule

Priorités proposées et charge indicative

Ordre conseillé

Priorité	Travail concret	Critère de sortie
1 - Intégration	Adapter le retriever, le contexte et l'interface aux quatre éditions ; rendre le filtre d'édition obligatoire ; relier chaque citation à la bonne page source.	Une question par édition fonctionne de bout en bout sur le candidat, sans toucher à l'actif.
2 - Cas difficiles	Examiner les alertes ciblées, les articles très longs, les notes incertaines et les dispositions proches entre années. Vérifier le budget réel du contexte parent et les abstentions.	Anomalies expliquées ou corrigées ; aucune troncature de contexte cachée.
3 - Évaluation	Étendre les questions avec preuves dans les quatre éditions et plusieurs parties du CGI. Comparer la présélection bornée à l'exhaustif, puis mesurer recherche, réponses, citations, confusions et latence.	Résultats séparés par édition, thème et type de disposition ; régressions connues visibles.
4 - Bascule	Conserver une version réversible, activer le nouvel index seulement si les seuils de qualité et le parcours Streamlit conviennent.	Configuration active et ZIP mis à jour uniquement après validation des tests.

Estimation prudente

L'intégration technique peut demander 1 à 2 jours. Le diagnostic ciblé des cas longs et des alertes peut demander 1 à 3 jours. Un benchmark assez diversifié, son exécution et l'analyse des erreurs peuvent demander 2 à 4 jours. Ces durées se chevauchent et dépendent surtout du temps d'annotation des preuves et des corrections découvertes ; elles ne sont pas une promesse de fin à une date donnée.

Conclusion de décision

La taille de 9 062 chunks n'est pas, à elle seule, un obstacle à cette architecture locale. Le risque principal est la qualité juridique des preuves et du contexte lorsque des articles longs ou des éditions semblables sont interrogés. Les 24 sondes techniques autorisent à poursuivre l'intégration ; elles n'autorisent pas encore à présenter les quatre éditions comme un système évalué de bout en bout.

Traces de la campagne : data/candidates/full_cgi/source_audit.json, extraction_diagnostics.json, index_summary.json, index/vector_summary.json, index/token_audit.json et preselection_comparison.json. L'application active reste identifiée par data/current_run.json.