Intégration des quatre éditions du CGI

Recherche, contexte, citations et interface - bilan technique

Périmètre de cette étape

Le corpus et les index des CGI 2023 à 2026, préparés précédemment, sont désormais utilisables par un chemin d'exécution candidat. L'application habituelle garde sa configuration et son index actifs. Le basculement définitif attend l'évaluation du corpus étendu.

Ce qui a été relié

Le nouveau retriever lit l'index BM25 candidat et les vecteurs E5/Chroma liés à leurs empreintes. Il impose l'édition avant le classement, demande au plus 64 candidats denses de cette édition, puis recalcule leur score exact avant la fusion hybride. L'encodage E5 des questions utilise le GPU local et contrôle la VRAM. Si la question désigne sans ambiguïté un article, la recherche est également limitée à cet article dans l'édition sélectionnée.

Le constructeur de contexte lit les articles candidats et conserve le mode parent borné par le budget de Qwen. Le générateur continue à sélectionner des lignes ; l'application reconstruit les citations en blocs et leur pagination depuis ces lignes. L'interface affiche les seules pages PDF effectivement citées, vérifie l'édition et l'empreinte du fichier source, et donne accès à l'image de la page originale.

Le lanceur ordinaire reste associé au corpus actif. Un lanceur distinct, scripts/start_ui_candidate.ps1, expose les quatre éditions. Les réponses d'essai sont enregistrées sous data/candidates/full_cgi/answers ; la ligne de commande accepte --scope full_cgi_candidate.

Chaîne candidate

Question et édition	Recherche	Réponse et preuve
Filtre d'édition obligatoire ; article explicite si indiqué.	BM25 + E5/Chroma borné, puis fusion RRF.	Contexte parent sous budget ; Qwen local ; citation en blocs, page PDF et page imprimée.

L'interface montre les éditions 2023, 2024, 2025 et 2026 uniquement dans ce mode candidat. Aucune campagne d'évaluation finale n'est implicite dans cette intégration.

Vérifications et limites

Résultats observés après l'intégration

Contrôle	Observation	Portée
Tests automatiques	79 tests passent ; les quatre éditions, le filtre, les pages et l'interface candidate sont couverts.	Régression fonctionnelle ciblée, pas mesure de qualité juridique globale.
Démarrage Streamlit	Le lanceur candidat a démarré ; l'endpoint local de santé a répondu « ok ».	Le serveur de test a été arrêté ; le parcours visuel avec l'utilisateur reste à faire.
Réponse CGI 2026	Qwen a cité l'article 1 ; page PDF 5, page imprimée 6 ; environ 13,7 s de traitement mesuré.	La citation renvoie au fichier original CGI_2026_FR.pdf et à la bonne édition.
Question CGI 2024	Le contrôle a rejeté une réponse sur l'article 2 : Qwen avait ajouté le chiffre 5, absent de la preuve citée.	Rejet explicite, à analyser dans l'évaluation des réponses.

Correction déclenchée par un essai réel

Avant le routage des demandes d'article explicites, la question « quel impôt est institué par l'article premier ? » renvoyait cinq passages de l'article 247. Après correction, le retriever a fourni l'article 1 de 2026 et Qwen a produit la citation correspondante. Cette correction ne prouve pas que les questions sans numéro d'article seront bien classées : un premier essai général sur les personnes passibles de l'IS plaçait l'article 2 seulement au rang 4.

Ce qui reste à vérifier avant une bascule

Évaluer la recherche et les réponses sur des questions réparties dans les quatre éditions et plusieurs parties du CGI ; analyser les confusions entre éditions, les rejets et les citations. Éprouver les articles très longs et le budget du contexte parent. Mesurer les latences à froid et à chaud avec E5 et Qwen ensemble, puis faire le contrôle visuel de l'interface et des pages source. La présélection à 64 candidats reste un réglage candidat appuyé par 24 sondes techniques, non par une évaluation exhaustive de pertinence.

État préservé

data/current_run.json, l'index actif, les résultats précédents et le ZIP de démonstration n'ont pas été remplacés. Les serveurs Streamlit et Ollama ouverts pour ces essais ont été arrêtés.

Traces : rag_fiscal/candidate_retrieve.py, rag_fiscal/context.py, rag_fiscal/ui_service.py, streamlit_app.py, tests/test_candidate_integration.py et data/candidates/full_cgi/answers/.