Évaluation consolidée du RAG fiscal

Éditions complètes du CGI marocain 2023, 2024, 2025 et 2026 · candidat isolé

Décision en une phrase

La chaîne candidate répond à 74 des 76 questions évaluées, sans erreur technique ni confusion d'édition observée ; deux réponses restent rejetées par les garde-fous. Le résultat justifie une démonstration du candidat, mais pas encore un taux d'exactitude générale de 74/76.

Ce qui a changé

Les ajustements portent sur la recherche et l'assemblage du contexte : diversité des articles remontés, sauvegarde du meilleur résultat lexical, titre et portée utiles aux listes, explicitation des exclusions, traitement de certaines ambiguïtés et contrôle plus strict des affirmations et citations. En cas de rejet, une reprise ciblée sur l'article le mieux classé est tentée une fois. Le corpus, le découpage des passages et l'index n'ont pas été modifiés pour cette campagne.

Résultats mesurés

Indicateur	Avant corrections	Candidat consolidé
Réponses délivrées / 76	66 (4 abstentions, 6 rejets)	74 (0 abstention, 2 rejets)
Anciennes 60 questions	53 réponses ; 1 abstention ; 6 rejets	58 réponses ; 2 rejets
Nouvelles 16 questions	13 réponses ; 3 abstentions	16 réponses ; 0 rejet
Rappel strict de preuve @ 5, ancien lot	51/60 (85,0 %)	52/60 (86,7 %)
Rappel strict de preuve @ 5, nouveau lot	15/16 (93,8 %)	16/16 (100 %)
Confusions d'édition dans le Top 5	0	0

« Réponse délivrée » désigne un statut technique accepté, non une vérification exhaustive de chaque affirmation. Parmi les 74 réponses, les liens de citation sont structurellement valides (article, édition, ligne et page). La revue sémantique détaillée s'est concentrée sur les 16 nouvelles questions et les cas corrigés.

Interprétation et limites du protocole

Le total est composé de 69 résultats du premier passage, de 2 reprises ciblant les exclusions et de 7 reprises après rejet. Il ne représente pas une nouvelle exécution simultanée des 76 questions sur une seule révision du code. Les 60 anciennes questions servent à la régression ; les 16 nouvelles forment un lot exploratoire déjà exposé. Ces résultats ne constituent donc pas une estimation indépendante de performance sur des questions inédites.

Diagnostic et suite du projet

Deux rejets sûrs demeurent ; les autres défauts observés concernent surtout la précision et la concision des citations.

Cas restants

q27 : la question vise une exception située après la durée générale. Le contrôle refuse la réponse lorsque le passage cité ne couvre pas clairement cette exception. q58 : la réponse sur un délai de six mois est rejetée car le bloc retenu ne démontre pas explicitement le nombre. Dans ces deux cas, le rejet évite une affirmation insuffisamment étayée.

Les cas repris q13, q41, q42, q52 et q57 ont obtenu une réponse appuyée par les passages attendus. q13 ajoute une exception sourcée mais non demandée ; q41 et q42 sont répétitives ; q57 cite davantage de blocs que nécessaire. Les nouvelles réponses fc05 et fc07 montrent respectivement des introductions superflues et une répétition. La couverture des citations peut donc être correcte sans que la présentation soit optimale.

Robustesse et coût

Contrôle	Observation
Questions difficiles hors benchmark	4/4 comportements attendus : conflit d'édition, hors sujet, taux ambigu, preuve absente.
Contexte parent sur articles longs	24/24 assemblages tiennent ; maximum 3 424 tokens dans cet essai.
Premier passage	Médiane 6,17 s ; 95e percentile 12,81 s.
Budget maximal observé	6 876 tokens de prompt pour 8 192 de contexte ; avec 1 200 réservés à la réponse et 64 de marge, il reste 52 tokens.
VRAM observée	Maximum échantillonné : 56,8 % ; ce relevé ne borne pas les pointes instantanées.

La proximité du budget de contexte sur le premier passage appelle une protection explicite lors de futurs changements de modèle ou d'articles très longs. La médiane de l'ensemble composite est 6,03 s, mais elle mélange les phases et ne doit pas être présentée comme celle d'une campagne unique.

État retenu et prochaine étape

Le candidat à quatre éditions est prêt pour la démonstration et la comparaison dans MLflow. La configuration active historique reste inchangée : son remplacement doit passer par un essai complet de l'interface et une bascule explicite, avec contrôle des liens vers les pages sources. Ensuite, il faudra tester sur un lot réellement inédit et cibler la citation des exceptions et des nombres, sans changer le découpage avant décision séparée.

Traçabilité : protocoles, résultats par question, résumé final et contrôles de robustesse sous data/experiments/four_edition_*_20261015 ; résumé consolidé dans data/experiments/four_edition_recovery_20261015/final_summary.json.